Система обнаружения мошеннических разговоров

Будицкий Егор Александрович, Б01-411

Реализация на github:`https://github.com/ZEVS1206/Test_task_SBER_ML`

Долгопрудный, 2026

Содержание

1 Описание алгоритма **2**
1.1 Методы оптимизации 2
1.2 Блок-схема: 3
1.3 Сравнительные диаграммы: 3
1.4 Немного про стратегии запуска 3

2 Планы на будущее **5**

1 Описание алгоритма

Для реализации поставленной задачи была выбрана двухслойная архитектура системы. Первый слой: модель распознавания речи Vosk, запускаемая только на CPU + сформированный словарь фраз-маркеров с весами для анализа полученного текста и отслеживания подозрительных слов. Если итоговый вес составляет не более 0.2, то разговор считается не мошенническим, если вес превышает 0.7, то подтверждается опасность разговора без дальнейшего анализа. Если же вес не определен(между 0.2 и 0.7), вызывается второй слой. Второй слой: достаточно тяжелая, но имеющая высокую точность в распознавании русской речи модель GigaAm v3, которая может быть запущена как на CPU, так и на GPU + тот же словарь и тот же подход с весом. Поскольку GigaAm дает более точную расшифровку, система может найти либо опровержение предположению первого слоя, либо подтверждение(правила для веса те же). Для повышения точности распознавания второго слоя для GigaAm была также использована технология VAD(Voice Activity Detection), она позволила максимально повысить правильность восприятия контекста.
В качестве "легкой"модели использовалась модель Vosk 0.22: `https://alphacephei.com/vosk/models/vosk-model-small-ru-0.22.zip` Поскольку модель запускается на CPU, то особенно при многопоточном исполнении достигается высокая скорость обработки, но возможна низкая точность. В основном первый слой отбрасывается от 65% до 80% опасных или безопасных файлов. Таким образом, достигается наилучшая эффективность, поскольку при запуске моделей поотдельности неизбежна потеря в точности или в производительности.

1.1 Методы оптимизации

Для оптимизации были предприняты некоторые шаги. Во-первых, если идет работа чисто на CPU, то используется многопоточный режим. На моем CPU: Intel Core i7 13700H (2.4 GHz), работа обоих моделей на 18 ядрах из 20 достаточно сильно нагружала систему(почти 100% работы). После подключения к рабочей среде моей видеокарты Nvidia RTX 4050 Mobile, была достигнута максимальная эффективность на гибриде многопоточного исполнения Vosk на CPU и однопоточного GigaAm + VAD на GPU. Ниже можно видеть сравнительную диаграмму и блок-схему алгоритма.

1.2 Блок-схема:

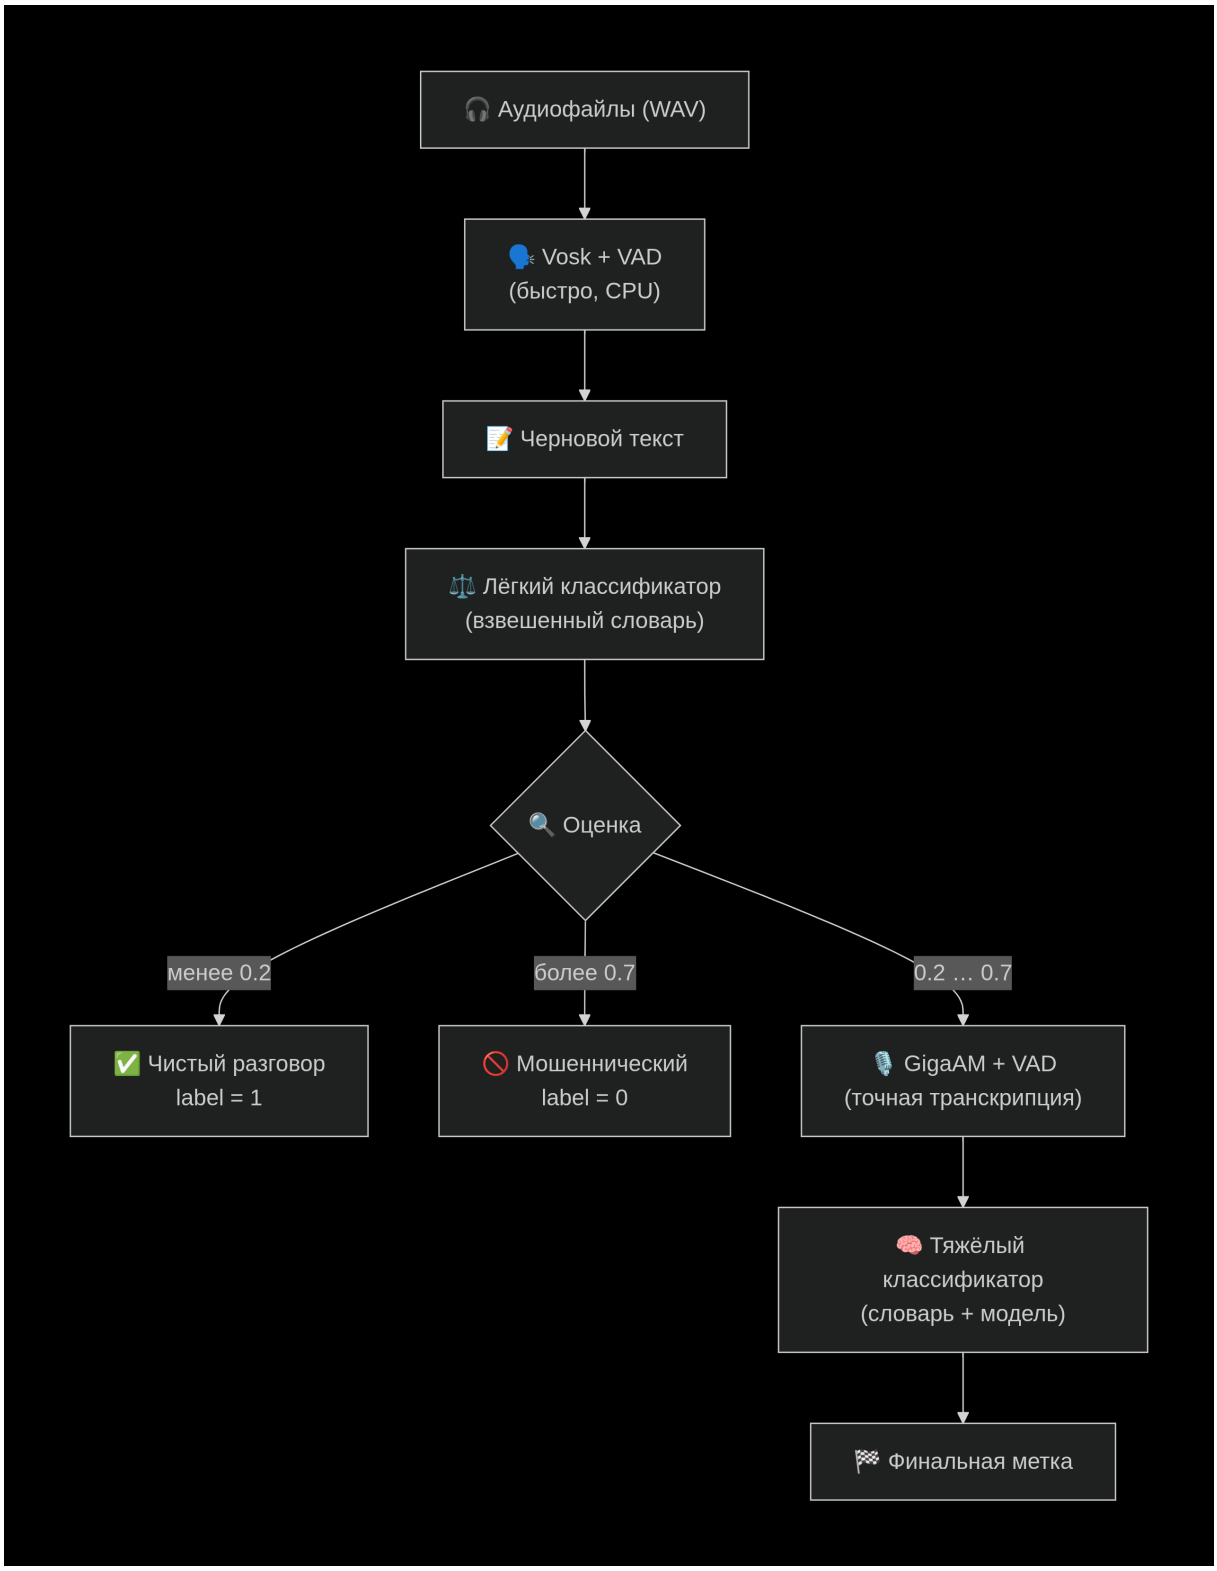

1.3 Сравнительные диаграммы:

1.4 Немного про стратегии запуска

Поскольку для работы на 16 процессов памяти видеокарты не хватает, то были выбраны некоторые стратегии для запуска на GPU:

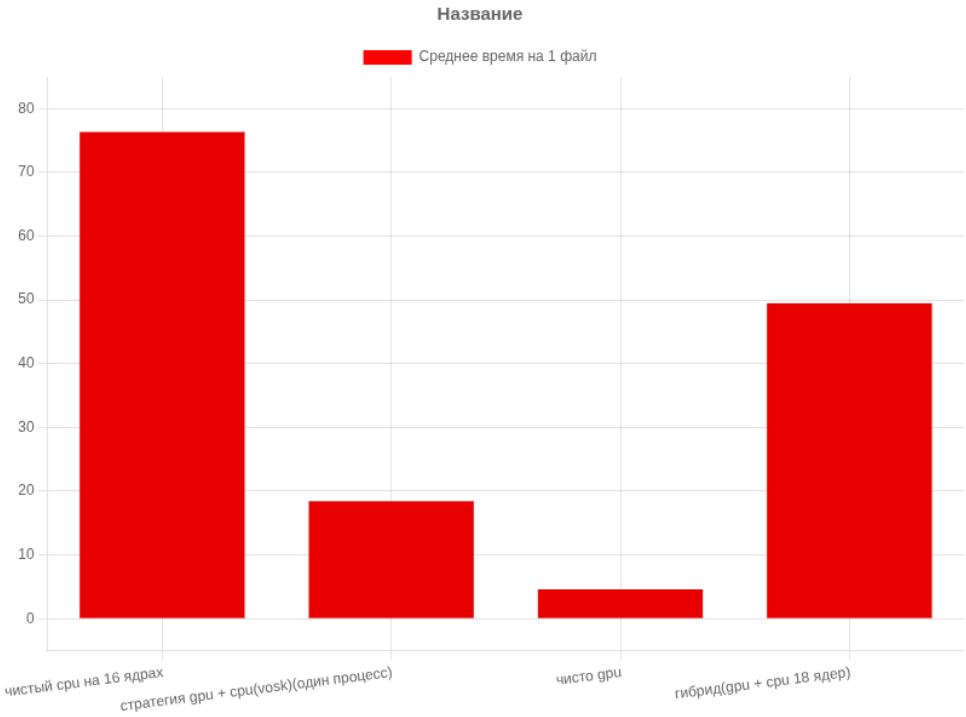

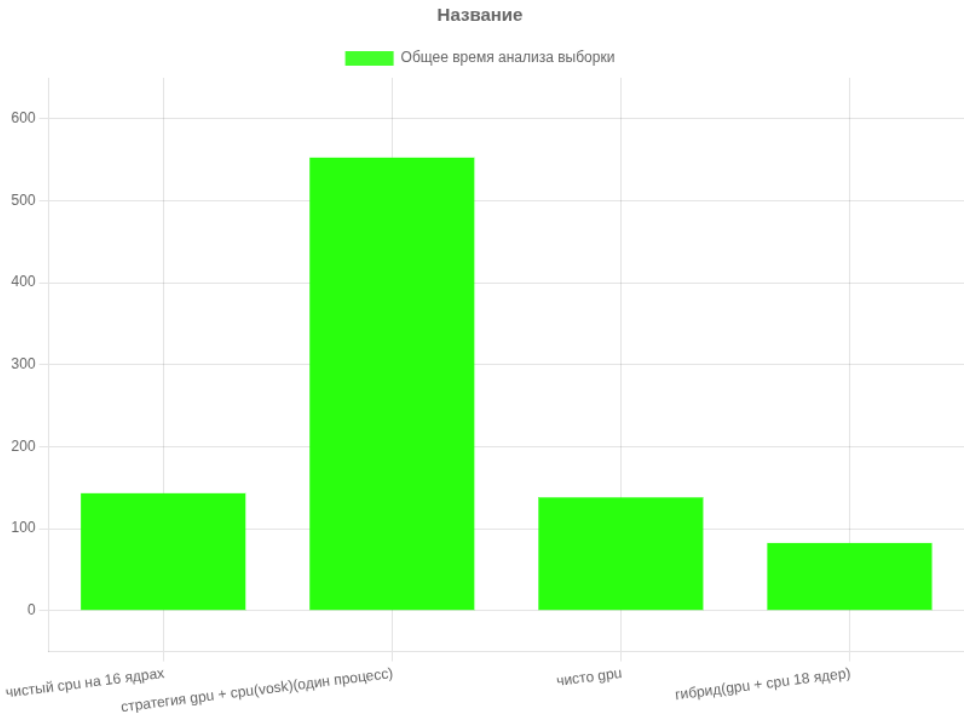

1. Все файлы засылаются поочереди в одном процессе с использованием GPU для каждого отдельного файла. Как видно из графиков, чистый GPU показал неплохой результат по среднему времени на файл, но при этом довольно посредственный результат по общему времени работы.
2. Используется стратегия очередей, когда при многопоточном выполнении происходит наполнение запросами очереди для GPU процесса. Данная стратегия показала наиболее сбалансированный результат.

2 Планы на будущее

В будущем планируется использовать во втором слое более серьезный классификатор для отслеживания не только слов-маркеров, но и эмоций собеседников, контекста разговора. Мною были приобретены для этого датасеты с телефонными разговорами, собираюсь на них и обучить модель.